

Спецификация API (CoPilot 2.0)

CoPilot API версии 2.0 представляет собой профессиональное решение, предоставляющее программный доступ к **безопасным внутренним** большим языковым моделям (LLM) через удобные API-интерфейсы.

На этой странице собрана **вся необходимая информация** для работы с CoPilot API.

Отдельно можете ознакомиться с **Инструкцией по использованию LLM-моделей через Copilot API**

Оглавление

- [Отличие от CoPilot API 1.0](#)
- [Быстрый старт](#)
- [Основные методы представленные в API](#)
- [Перечень доступных провайдеров и моделей](#)
- [Перечень доступных моделей](#)
- [API для разработчика](#)
- [Примеры обращений](#)
- [Что дальше ?](#)

Отличие от CoPilot API 1.0

Главное нововведение - поддержка toolcalling (вызовов функций) в формате OpenAI. Это позволяет:

- Моделям запрашивать выполнение внешних функций (Tools calling)

Технические изменения:

- Полная поддержка OpenAI формата
- Новые параметры в запросах для работы с функциями
- Выше надежность и отказоустойчивость
- Меньше задержки в обработке запросов
- Поддержка стриминга

Быстрый старт

Кто вы?

- └─ Частное лицо (пользователь веб-интерфейса / разработчик)?
 - └─> Получите токен в личном кабинете: <https://copilot.x5.ru/copilot-api>
 - └─> Используйте любой из Base URL ниже.
 - └─> Переходите к [Основным методам API](#) или к [API для разработчика](#).
- └─ Представитель платформы или продукта (интеграция)?
 - └─> Зарегистрируйтесь как клиентская система: обратитесь к [Semchenkov, Dmitry](#)
 - └─> После регистрации получите токен клиентской системы
 - └─> Воспользуйтесь выбранным на этапе регистрации способом подключения
 - └─> При необходимости получать полноценную поддержку, обратитесь к [Fonotov, Mark](#) для выстраивания процесса поддержки как клиентской системе.

Base URL:	https://api-copilot.x5.ru/v1/
Base URL:	https://api-copilot.x5.ru/aigw/v1/



Внимание

При обращении к API необходимо добавить **Endpoint** из таблицы основных методов API к **Base URL**.

Например:

<https://api-copilot.x5.ru/aigw/v1/chat/completions>

Рекомендуем сначала ознакомиться с перечнем доступных моделей, используя endpoint [GET /models](#) для соответствующего **BaseUrl**.

Основные методы представленные в API

Ресурс	Описание
Получение информации	
GET /api_key/info	Получение информации по токenu
GET /models	Получение списка доступных моделей
OpenAI-like Completion	
POST /completions	Текстовая генерация
OpenAI-like Chat Completion	
POST /chat/completions	Генерация текста в диалоге
OpenAI-like Embedding	
POST /embeddings	Получение векторного представления текста
Audio Transcription	
Тестовый режим Работа может быть нестабильна POST /audio/transcriptions	Распознавание речи в аудио-файле (формата: mp3, mp4, mpeg, m4a, wav, и webm)

Ознакомьтесь с перечнем моделей предоставляемыми CoPilot API

Перечень доступных провайдеров и моделей

Наиболее актуальный перечень доступных вам моделей **в зависимости от способа интеграции** вы можете получить по запросам:

Доступные базовые URL, списки по ссылке:	
GET	(CoPilot API 2.0) https://api-copilot.x5.ru/aigw/v1 - ссылка для вызова моделей https://api-copilot.x5.ru/aigw/v1/models - список моделей
GET	https://api-copilot.x5.ru/v1/models (CoPilot API)

GET	https://direct-llm.k8s.airun-prod-1.salt.x5.ru/v1/models при интеграции "система-система" через AI-Run BP (авторизация обязательна)
-----	---

Перечень доступных моделей

Имя модели для:	Имя модели для:	Размер контекста (токенов)	Ключевые возможности / Примечания
CoPilot API 2.0 https://api-copilot.x5.ru/aigw/v1	- AI-Run BP API (REST) - AI-Run BP API (Kafka) - CoPilot API		
x5-airun-large	x5/x5-airun-large-prod	131,072	Крупная модель. DeepSeek V4 Flash – Генерация научных текстов, анализ. Большая точность – большее время на генерацию.
x5-airun-medium	x5/x5-airun-medium-prod	65,536	Qwen3.6-27B-FP8. Адаптирована для работы с русским языком. Подходит для сложных задач, требующих глубокого понимания контекста. Модель используется для выполнения образовательных, юридических и технических задач на русском.
x5-airun-small	x5/x5-airun-small-prod	65,536	Qwen3.6-35B-A3B-FP8. Размышляющая модель. Архитектура включает 14 миллиардов параметров. Подходит для задач генерации текста, ответов на вопросы, решения простых задач. Модель используется для создания чат-ботов и виртуальных ассистентов.
[] x5-airun-medium-coder	[] x5/x5-airun-medium-coder-prod	–	Перенаправляется в copilot-flash.
copilot-flash	x5/copilot-flash	131,072	Qwen3-coder-next. Языковая модель, общего назначения. Используется для быстрой генерации ответов.
x5-airun-small-coder	x5/x5-airun-small-coder-prod	8,273	Qwen2.5-Coder-1.5B-Instruct-AWQ. Языковая модель, предназначенная для выполнения задач автокомплита . Оптимизирована для работы с кодом и поддерживает множество языков программирования. Быстрее в обработке запросов и менее требовательна к ресурсам, но может уступать в качестве и глубине анализа.
x5-airun-multilingual-e5-large	x5/x5-airun-multilingual-e5-large	512	Модель для расчета эмбедингов. Подходит для классических задач поиска и семантического текстового сходства. Подойдет для: - Поиск документов по запросу (Dense Retrieval). - Кластеризация текстов. - Дубликация или near-duplicate обнаружение.
-	x5/x5-airun-multilingual-e5-large-instruct	512	Универсальные текстовые эмбединги, особенно для задач, связанных с инструкциями и диалогом. Подойдет для : - Мультизадачных систем, где одна модель используется для разных целей (поиск, классификация, кластеризация). - RAG-системы, где запросы сложные и контекстно-зависимые. - Ситуации, когда вы хотите гибко управлять поведением модели через текстовые инструкции.
-	x5-asr/x5-asr-large	–	Предназначена для распознавания текста в аудиофайлах. Крупная модель, отличается повышенным качеством распознавания речи. Возвращает транскрибированный текст. На нее же происходит редирект запросов от x5-asr/whisper-3-large-turbo-ru
-	x5-asr/x5-asr-small	–	Предназначена для распознавания текста в аудиофайлах. Малая модель, отличается быстроействием. Возвращает транскрибированный текст.
copilot-code-large	x5/copilot-large	196,000	Она же MiMo-V2.5-Pro. Размышляющая , передовая мощная модель, специально оптимизированная для решения сложных задач программирования, анализа кода и интеллектуальной автоматизации разработки. Не предназначена для высокочастотных сценариев интеграции типа "система-система"

x5-airun-embed-4b	x5/copilot-embed-4b	2560	Она же Qwen3-Embedding-4B. модель для создания текстовых эмбедингов. Предназначена для задач поиска, классификации и ранжирования текстов.
copilot-code-large-exp	-	196,000	Экспериментальная модель для кода. Потенциальная замена GLM4.7  Модель экспериментальная: доступность будет варьироваться
x5-airun-vlm-medium	x5/x5-airun-vlm-medium-api	128,000	Она же Qwen3-32b-VL. Мультимодальная, размышляющая модель . Анализ изображения, графиков, схем. Показывает размышления.

API для разработчика

Инструкции
Руководство по работе с API для разработчиков

Далее используйте Ваш API-Кей, полученный на странице <https://copilot.x5.ru/copilot-api>. Теперь воспользуйтесь примером использования сервиса CoPilot API 2.0

Примеры обращений

Здесь представлены примеры запросов и ответов, выполненные с помощью различных инструментов:

cURL – Chat Completions

```
curl --location 'https://api-copilot.x5.ru/v1/chat/completions' \
--header 'Content-Type: application/json' \
--header 'Authorization: Bearer <api_key>' \
--data '{
  "provider": "x5",
  "model": "x5/x5-airun-medium-prod",
  "messages": [
    {"role": "user", "content": "    "}
  ],
  "frequency_penalty": 0.5,
  "presence_penalty": 0.5,
  "temperature": 0.5,
  "top_p": 1,
  "max_tokens": 1000,
  "n": 1,
  "seed": 12,
  "logit_bias": {"22": 0},
  "stream": false
}'
```

Python – Chat Completions ([инструкция по установке OpenAI lib](#))

```
from openai
import OpenAI

client = OpenAI(
    base_url = 'https://api-copilot.x5.ru/aigw/v1/',
    api_key = "<api_key>"
)

response = client.chat.completions.create(
    model = "x5-airun-medium",
    messages = [{
        "role": "user",
        "content": "    "
    }]
)

print(response.choices[0].message.content)
```

Python – Chat Completions (Requests lib)

```
import requests

base_url = "https://api-copilot.x5.ru"
headers = {
    "Authorization": f "Bearer <api_key>"
}

json = {
    "provider": "x5",
    "model": "x5/x5-airun-small-coder-prod",
    "messages": [{
        "role": "user",
        "content": " "
    }],
    "frequency_penalty": 0.5,
    "presence_penalty": 0.5,
    "temperature": 0.5,
    "top_p": 1,
    "max_tokens": 1000,
    "n": 1,
    "seed": 12,
    "logit_bias": {
        "22": 0
    },
    "stream": False,
}

response = requests.post(url = f "{base_url}/v1/chat/completions", headers = headers, json = json)

print(response.json())
```

Пример ответа – Chat Completions

```
{
  "id": "efb120e818e2cc7a0fa08a3da06e8e0c",
  "model": "x5/x5-airun-medium-prod",
  "created": 1759228931,
  "system_fingerprint": null,
  "usage": {
    "completion_tokens": 85,
    "prompt_tokens": 27,
    "total_tokens": 112
  },
  "object": "chat.completion",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "*** ** - , * * * * ,",
      ".
      ,
      .
      ,
      "reasoning_content": null,
      "tool_calls": []
    },
    "finish_reason": "stop"
  }]
}
```

Python – Automatical Speech Recognition ([инструкция по установке OpenAI lib](#))

```
from openai
import OpenAI

client = OpenAI(
    base_url = 'https://api-copilot.x5.ru/v1/',
    api_key = "<api_key>"
)

response = client.audio.transcriptions.create(
    file = open('/Users/user/Downloads/asr.mp3', 'rb'), # model = 'x5-asr/whisper-3-large-turbo-ru', # (:
    mp3, mp4, mpeg, m4a, wav, webm)
)

print(response)
```

Пример ответа – Automatical Speech Recognition

```
Transcription(  
  text = ' , , , ?  
    , , . . . , ?  
    , ? ? , , ? ? ? , , ,  
    . , , . , ?  
    . , , ,  
    , , , ,  
    .  
,  
  logprobs = None,  
  usage = UsageTokens(  
    input_tokens = None,  
    output_tokens = None,  
    total_tokens = 85,  
    type = None,  
    input_token_details = None)  
)
```

Что дальше ?

Для продвинутого использования CoPilot-API 2.0, а также для получения информации о параметрах запроса рекомендуем ознакомиться с документацией:

[OpenAI-docs](#)

CoPilot API поддерживает формат Open AI – обращения возможны через стандартную библиотеку OpenAI.